




Mini Global AI Assessment

Decisiones técnicas y de producto detrás de una evaluación de inglés que se siente como hablar con alguien.

Hi, I'm Glo.
Tu coach de inglés.



Hello / Hola / Ciao / Bonjour / Hallo / Olá / Merhaba / He

EN 30 SEGUNDOS

Una evaluación que conversa, un backend que no se deja engañar.

El estudiante entra, Glo lo acompaña por 13 preguntas de cinco habilidades, incluida su propia voz, y al terminar recibe su nivel MCER, un feedback con IA que puede escuchar y un curso recomendado. Todo lo que decide la nota vive en el servidor.

5 habilidades: Grammar, Vocabulary, Reading, Listening y Speaking	6 niveles MCER (Pre-A1 → C1) como datos , no como código	0 respuestas correctas enviadas al navegador antes de entregar	68 tests automatizados + CI con Postgres real y smoke test en Docker
---	---	--	--

Producto

Glo, un coach con personalidad

Mascota 3D propia (Three.js) que reacciona a lo que haces, habla con voz real, te entrega un sombrero según tu nivel y te da una mini clase de pronunciación con conversación.

Seguridad

El servidor es el único juez

Calificación en el servidor, preguntas y opciones barajadas por intento, variantes que rotan, bitácora de integridad y resultado congelado e inmutable.

Negocio

Del resultado a la matrícula

Curso recomendado según nivel y habilidades débiles, presentado por Glo con voz, tarjeta para compartir el nivel en redes y un panel docente con alertas.

Lo que pedía la prueba y lo que se entregó

REQUISITO	IMPLEMENTACIÓN
Login	Cookie <code>httpOnly</code> con JWT, rate limit por IP+email, consentimiento versionado de Términos y Privacidad.
Test de 10 preguntas	10 preguntas de 4 tipos (4 opción múltiple, 2 completar, 2 comprensión, 2 vocabulario) + 3 de Speaking con voz real. Banco de 39 preguntas con variantes por posición.
Calificación en servidor	Funciones puras en <code>domain/scoring.py</code> ; la clave de respuesta nunca se serializa hacia el cliente.
Resultados, intentos y progreso	Desglose por habilidad y nivel, nivel MCER sugerido y revisión pregunta a pregunta. Cada intento es un snapshot inmutable y el dashboard muestra la evolución.
Feedback con IA	Coach desacoplado del proveedor, con respaldo por plantilla. También se puede escuchar con voz de ElevenLabs.
Extra	Panel docente, mini clase de pronunciación con conversación, curso recomendado, modo offline, tema oscuro, versión móvil y CI/CD.

LA EXPERIENCIA

Sin landing. Glo te recibe.

El login es la portada: Glo es el protagonista, reacciona mientras escribes (y se tapa los ojos cuando escribes la contraseña) y te saluda en muchos idiomas.

Login. Tipografía cinética, formulario en forma de globo de diálogo y cuentas demo visibles (estudiante y profesor) para que el evaluador entre en un clic.

Evaluación. Una pregunta por pantalla, atajos de teclado (A-D, Enter), temporizador, guardado automático visible y Glo explicando cada tarea en inglés con la traducción debajo.

Móvil. Glo se asoma sobre la tarjeta.

EL MOMENTO DEL RESULTADO

Un nivel que se celebra, no una nota que se lee.

Glo recibe un sombrero según el nivel (gorro de fiesta de Pre-A1 a A2, bombín británico en B1-B2, birrete en C1), lee el feedback en voz alta y presenta el siguiente paso.

You're A2. Let's celebrate!

Estás en A2. ¡A celebrar que empezaste!

62% 8 de 13 correctas

English Placement Assessment

Nivel sugerido

A2 Elementary [Compartir mi nivel](#)

Pre-A1 A1 **A2** B1 B2 C1

Se comunica en tareas simples y rutinarias sobre temas conocidos.

correctas	incorrectas	sin responder	tiempo
8	3	2	2 min

Glo dice

[Escuchar a Glo](#)

Tu puntaje global de 62% indica que te encuentras en un nivel A2 (Elementary). Has tenido un buen desempeño en gramática y comprensión auditiva, pero hay áreas que requieren atención, especialmente en lectura y vocabulario.

El error más importante fue en la gramática, donde no respondiste a la pregunta sobre el futuro perfecto. La oración correcta es "By the time you arrive at the party, we *will have eaten* all the pizza." Esto muestra que aún necesitas practicar la formación de tiempos verbales.

Esta semana, te recomiendo que te enfoques en leer textos cortos en inglés y responder preguntas sobre ellos. Esto te ayudará a mejorar tu comprensión lectora y vocabulario.

Tu siguiente paso

Everyday English

Nivel A2 · 10 semanas para desenvolverte en viajes, compras y el trabajo.

Con foco en **Reading** y **Vocabulary**.

[Quiero empezar](#) [Que Glo te lo cuente](#)

Te atiende un asesor de Global por WhatsApp.

Resultados. Puntaje, nivel MCER en una escala visual, desglose y feedback del coach. La tarjeta azul es el curso recomendado, con botón para que Glo lo cuente con su voz.

+23 points, Laura. Nice!

¡23 puntos más que en tu intento anterior, Laura!

[Repetir evaluación](#) [Practicar pronunciación](#)

13 preguntas / 25 min / Guardado automático

intentos	mejor puntaje	vs. anterior
21	62%	+23

Tu siguiente paso

English Starter

Nivel Pre-A1 · 8 semanas

[Quiero empezar](#)

Tu nivel

PRE-A1 Pre-Beginner

Primer contacto con el idioma: palabras y frases aisladas.

Pre-A1 A1 A2 B1 B2 C1

Por habilidad

Habilidad	Progreso	Porcentaje	Cambio
Grammar		20%	+20
Reading		0%	=
Speaking		67%	+67
Listening		0%	=
Vocabulary		0%	=

Últimos intentos


Fecha y hora	Nivel	Puntaje	Acción
24 sept, 18:57	PRE-A1	23%	→
24 sept, 18:55	PRE-A1	0%	→
24 sept, 17:44	A2	62%	→

Dashboard. Todo cabe en una pantalla sin scroll: progreso respecto al intento anterior, tendencia por habilidad, últimos intentos, curso recomendado y acceso a la mini clase de pronunciación.

LO MÁS NUEVO

Una mini clase y una conversación real con Glo.

Desde el dashboard, "Practicar pronunciación" abre una clase de un minuto: un sonido difícil para hispanohablantes, una palabra modelo y una charla corta en la que Glo corrige lo que dijiste y te responde con voz.



Mini clase «i corta». La página se atenúa y Glo pasa al centro (escenario compartido stage.ts, el mismo en todos los lugares donde habla). Los anillos siguen el volumen real del audio.

Cómo funciona

1 · Glo explica y pronuncia

Audio TTS de ElevenLabs. La palabra modelo va en un clip aparte: dentro de una frase en español la voz la decía con acento ("think" sonaba "pink").

2 · El estudiante repite

Speech-to-text (Scribe) con confianza por palabra: se acepta si la palabra aparece y la claridad es ≥ 0.6 ; si no, «Casi. Escúchala otra vez».

3 · Charla de 2 turnos

El LLM devuelve JSON `{reply, fix, why}`: primero la corrección para imitarla, luego la respuesta y una pregunta.

Ejemplo de turno

Now, let's talk! What did you do this weekend?

I go to the beach with my family.

You can say: "I **went** to the beach with my family."

Pasado de "go" → "went".

That sounds lovely! Did you swim in the sea?

Ejemplo ilustrativo del formato. Las frases fijas se sintetizan una vez y quedan en caché; por estudiante solo se paga la transcripción y respuestas de ≤ 25 palabras. La transcripción entra al prompt como dato a ignorar si trae órdenes (defensa contra prompt injection).

RECOMENDACIÓN DE CURSOS

Cada resultado termina en un siguiente paso.

Una evaluación de nivel en una EdTech es la puerta de entrada a la matrícula. Por eso el resultado no se queda en un número: propone un curso concreto y lo presenta Glo.

Curso recomendado, determinista

El LLM redacta el feedback, pero nunca decide qué curso se vende. La regla vive en `domain/courses.py`: curso según el nivel sugerido y foco en las (hasta 2) habilidades por debajo del 80%.

NIVEL	CURSO	SEMANAS
Pre-A1	English Starter	8
A1	English Foundations	10
A2	Everyday English	10
B1	Confident Communicator	12
B2	Professional English	12
C1	C1 Mastery & Certification	10

Glo lo presenta con voz

«Te recomiendo el curso Everyday English, nivel A2. Son 10 semanas para desenvolverte en viajes, compras y el trabajo. Pondremos foco en Reading y Vocabulary...». El guion se arma en el servidor y el audio se genera una vez por intento.


Compartir el nivel

Imagen para historia (9:16) o post (4:5) dibujada en `<canvas>` con Glo y su sombrero, sin librerías. El nivel es identidad («Soy B1») y la imagen cierra con un reto para quien la ve: marketing orgánico.

CTA a un asesor

«Quiero empezar» abre WhatsApp con el curso y el nivel ya escritos (número de demostración en `lib/sales.ts`).

Panel docente



/teacher. Niveles del grupo, promedio por habilidad y alertas priorizadas (puntaje bajo, caída, respuestas en < 3 s, posible ayuda externa, tiempo agotado). Reglas en el servidor (`teacher_service.py`) y exportación CSV.

VISTA GENERAL

Dos apps, un contrato claro.

Frontend y API se despliegan por separado. El navegador solo presenta; toda regla que afecte una nota, un permiso o un costo vive en la API.



Decisiones de stack

ELECCIÓN	POR QUÉ	ALTERNATIVA DESCARTADA
Astro	Envía HTML y solo el JS que cada página necesita: carga rápida en conexiones modestas, que es donde está buena parte del público de LatAm.	SPA en React/Next: más JS por defecto para un flujo mayormente lineal.
FastAPI async	Validación con Pydantic en el borde, OpenAPI gratis (Swagger en /docs) y async para no bloquear mientras se espera a la IA.	Django: más completo, pero más peso del necesario para una API.
PostgreSQL	Transacciones reales (FOR UPDATE al enviar), índices parciales y JSONB. Funciona igual en Neon, Supabase o RDS.	NoSQL: perdería integridad relacional entre intentos, preguntas y niveles.
Cookie httpOnly	JavaScript no puede leer el token: un XSS no roba sesiones. Bearer también se acepta para Swagger y futuras apps móviles.	JWT en localStorage.
Three.js propio	Glo es un personaje con poses interpoladas cada frame, sin assets externos: pesa poco y es único de la marca.	Lottie o GIF: sin reacciones en vivo.
uv + ruff	Instalación reproducible con uv.lock ; lint y formato en un solo paso de CI.	pip + requirements sueltos.

BASE DE DATOS

Diseñada para crecer sin rehacerse.

Niveles, habilidades y preguntas son filas, no código. Agregar C2, un curso nuevo o una habilidad como Writing no requiere migrar el esquema.

levels · skills

Catálogo. `levels.rank` define el orden de dificultad.

questions

Banco reutilizable: tipo, formato de respuesta, habilidad, nivel, opciones y `answer_key` (JSONB, *sensible*).

stimuli

Lectura o audio compartido por varias preguntas. La transcripción del Listening nunca sale antes del envío.

assessments

Configuración: tiempo límite, intentos máximos, espera entre intentos, barajar preguntas y opciones.

assessment_questions

Posición y puntos. **Varias preguntas en la misma posición = variantes equivalentes.**

users

Rol (student, teacher, admin) y versión de Términos aceptada con su fecha.

attempts

Estado, `layout` generado por el servidor, vencimiento, puntaje, desglose y feedback: `snapshot immutable`.

attempt_answers

Una fila por pregunta (UNIQUE intento+pregunta): el autoguardado es un *upsert* idempotente.

attempt_events

Bitácora de integridad: cambio de pestaña, pegar, salir de pantalla completa, reanudación y señales del servidor.

Decisiones que importan

Un solo intento abierto, garantizado por la base

Índice parcial único (`user_id, assessment_id`) WHERE `status = 'in_progress'`. Un doble clic o dos pestañas no crean dos intentos: el segundo choca con el índice y reanuda el primero.

El resultado se congela

Al enviar se guardan puntaje, nivel y desglose en el propio intento. Si mañana cambia una regla o una pregunta, el historial del estudiante no se reescribe.

Enums como VARCHAR

Tipos y estados son `StrEnum` guardados como texto (no enum nativo de Postgres): agregar un tipo de pregunta no exige migración.

Layout por intento

El servidor elige una variante por posición (la que el estudiante *menos* ha visto), baraja el orden y las opciones y lo guarda en `attempts.layout`. Reanudar muestra exactamente lo mismo; repetir trae preguntas nuevas, así que memorizar la revisión no sirve.

Índices pensados para las consultas

(`user_id, submitted_at`) para el historial del dashboard; FK indexadas en respuestas y eventos. Naming convention fija para que Alembic genere migraciones estables.


Progreso

Se deriva de los intentos (no hay una tabla duplicada que pueda desincronizarse). A escala se agrega una tabla de resumen por estudiante, actualizada al enviar.

ANTI-TRAMPA

El navegador propone, el servidor decide.

Se asume que el estudiante puede abrir DevTools, editar peticiones y repetir llamadas. Nada de eso cambia su nota.



Integridad de la evaluación

- **Speaking calificado en el servidor:** el audio llega crudo; la transcripción y el puntaje los calcula la API. Antes del envío el cliente solo ve lo que se entendió, no el puntaje. Máximo 3 grabaciones por pregunta.
- **Listening sin transcripción:** el audio se sirve por su propio endpoint y un audio de una evaluación no publicada da 404.
- **Tiempo con reloj del servidor y 30 s de gracia** por latencia. Al vencer se califica solo lo guardado a tiempo.
- **Señales derivadas por el servidor:** respuestas en menos de 3 s y respuestas cambiadas al volver de otra pestaña. El cliente no puede enviarlas ni borrarlas.
- **Evidencia, no veredicto:** las señales nunca bajan la nota; alertan al profesor. Reanudar tras un corte no cuenta como sospechoso.

Cuentas y API

- **bcrypt** (12 rondas) ejecutado en un hilo para no congelar el event loop; se verifica un hash falso si el usuario no existe (sin enumeración por tiempo de respuesta).
- **Rate limits** con ventana deslizante: 5 intentos fallidos por IP+email, 50 por IP, 120 peticiones/min por usuario y 10/min en endpoints que gastan en IA.
- **Roles** con `require_roles(TEACHER, ADMIN)` a nivel de router, y cada intento se busca siempre filtrado por su dueño.
- **Arranque seguro:** en producción la API no inicia si `JWT_SECRET` es el de desarrollo o tiene menos de 32 caracteres.
- **Cabeceras:** `CSP default-src 'none', nosniff, X-Frame-Options: DENY, X-Request-ID` y log por petición. Swagger desactivado en producción.
- **Subida de audio acotada** leyendo el stream por partes (5 MB), también con `Transfer-Encoding: chunked`.
- **Privacidad:** al LLM solo viajan puntajes y respuestas, nunca nombre ni email. Consentimiento con versión y fecha.

REGLAS EXPLICABLES

Una nota que se puede defender.

La calificación son funciones puras, sin base de datos ni HTTP (`domain/scoring.py` , `domain/speaking.py`). Se prueban en milisegundos y un profesor puede entender por qué salió cada número.

Respuestas escritas

Normalización Unicode (NFKC), minúsculas, espacios colapsados, sin puntuación final y apóstrofes tipográficos unificados: `"Don't."` = `"don't"`. Varias respuestas aceptadas por pregunta.

Nivel sugerido

Se recorre de menor a mayor. Un nivel se alcanza con **≥ 50% en ese nivel** y **≥ 60% acumulado** en ese nivel y los inferiores. El acumulado evita que un error aislado en A1 hunda a alguien que domina B1, y el umbral propio evita "saltar" niveles.

Speaking con cuatro métricas defendibles

Scribe no evalúa pronunciación, pero su salida (texto, tiempos y confianza por palabra) alcanza para medir:

- **Precisión:** qué parte del texto se entendió (lectura en voz alta).
- **Contenido:** rúbrica 0–4 del LLM en tarea, gramática y vocabulario (respuesta libre).
- **Claridad:** confianza media del reconocedor.
- **Fluidez:** palabras por minuto (referencia 110) y pausas largas.

`score = contenido × (0.6 + 0.2·claridad + 0.2·fluidez)`. La entrega modula el contenido, no lo reemplaza: leer otra cosa con fluidez vale ~0.

IA desacoplada, con respaldo y costo acotado

Cambiar de IA = un campo del .env

`AI_PROVIDER=anthropic` , `openai` o `mock` , sin tocar código. Con `OPENAI_BASE_URL` sirve cualquier API compatible (Groq, OpenRouter, Ollama, Gemini). Todo pasa por `CoachProvider.complete()` .

Nunca bloquea

Sin key o si el proveedor falla: feedback por plantilla, rúbrica heurística con techo del 75% y respuesta genérica en la charla. El estudiante siempre recibe su resultado. Las salidas del LLM se validan como JSON y se recortan.


Costo por estudiante

El feedback se genera **una vez por intento** y queda guardado. El audio TTS se cachea. Hay un límite de 10 llamadas/min por usuario en rutas pagas. Modelo por defecto: `gpt-4o-mini` .

El LLM redacta, explica y conversa. **Nunca** decide una nota de opción múltiple, un nivel ni qué curso se ofrece.

SI SE CAE EL WIFI

Perder conexión no es perder el examen.



Además, el envío final incluye las respuestas pendientes, el servidor acepta 30 s de gracia tras el límite y un service worker muestra una página offline con Glo en vez del error del navegador.

Pruebas automatizadas

SUITE	TESTS	QUÉ PROTEGE
test_attempts_api	24	Flujo completo, dueño del intento, envío idempotente, vencimiento, respuestas ocultas
test_scoring	14	Normalización, crédito parcial, nivel sugerido
test_speaking	9	Precisión, claridad, fluidez, rúbrica malformada
test_teacher_api	6	Permisos por rol y reglas de alertas
test_integrity	5	Señales derivadas por el servidor
test_practice	4	Mini clase y charla
consent · coach_ai	3	Términos versionados, sin datos personales al LLM, proveedor por .env

Por qué estos primero

Se prioriza lo que, si falla, rompe la confianza en la nota: que las respuestas no se filtren, que el puntaje no se pueda manipular y que el nivel sugerido sea correcto. La interfaz cambia seguido; esas reglas no.

CI/CD en GitHub Actions

- **api:** ruff (lint y formato) + pytest contra **Postgres 17 real**, no SQLite.
- **web:** build de producción de Astro.
- **smoke:** docker compose up con migraciones y seed, y health check tal como lo correría un evaluador.
- **publish:** si todo pasa en `main`, se publica la imagen de la API en GHCR.

Accesibilidad e inclusión

Lexend a 18 px (diseñada para mejorar la lectura), contraste AA en tema claro y oscuro, foco visible, `aria-live` en estados, respeto de `prefers-reduced-motion`, subtítulos cuando Glo habla y textos bilingües: inglés grande y la traducción al español debajo.

RESPUESTAS CORTAS, CON EVIDENCIA EN EL CÓDIGO

Las 10 preguntas, respondidas.

01 De 100 a 100.000 estudiantes

La API ya es stateless (JWT), así que escala horizontal detrás de un balanceador. Los cambios: rate limit y caché de audio a Redis y S3/R2 (hoy en memoria por proceso), PgBouncer frente a Postgres, generación de feedback en una cola y una tabla de resumen para el panel docente. Detalle en la página siguiente.

02 Que no se vean las respuestas desde el navegador

Nunca llegan: `answer_key` no está en ningún schema de salida previo al envío, el Listening no trae transcripción y el Speaking se califica en el servidor. Un test lo verifica.

03 Dónde guardar el progreso y cómo modelar intentos

En Postgres. `attempts` es un snapshot inmutable con su layout; `attempt_answers` guarda una fila por pregunta (upsert) y `attempt_events` la bitácora. El progreso se deriva de los intentos, indexado por `(user_id, submitted_at)`.

04 Agregar Pre-Beginner, A1, A2, B1, B2 y C1

Ya están: los niveles son filas de `levels` con un `rank`. Un nivel nuevo es un INSERT, más preguntas etiquetadas con él. El algoritmo de nivel sugerido recorre lo que exista.

05 Reemplazar Claude u otro modelo de IA

Ningún archivo de código: se cambia `AI_PROVIDER` (y su key) en el `.env`. Claude y OpenAI vienen integrados y `OPENAI_BASE_URL` abre cualquier API compatible. Un test lo verifica.

06 Permisos de estudiante, profesor y administrador

Rol en `users`, incluido en el JWT pero verificado contra la base en cada petición. `require_roles()` protege routers enteros y los datos del estudiante se filtran siempre por su dueño.

07 Pérdida de conexión durante la evaluación

Cola local, `PUT` idempotentes, reanudación exacta del intento, gracia de 30 s y página offline. Reanudar se registra, pero no se trata como sospechoso.

08 Que no pueda modificar su puntuación

No existe un endpoint que acepte un puntaje. Se calcula al enviar, bajo `FOR UPDATE`, con lo guardado en la base, y queda congelado en el intento.

09 Qué pruebas primero

Reglas de calificación (puras y rápidas) y la API del intento: filtración de respuestas, envío idempotente, vencimiento y permisos. Después, integración de proveedores con mocks y un E2E del flujo feliz.

10 Producción en tres meses

Primero: observabilidad, backups, Redis, colas, más banco de preguntas validado por el equipo académico y calibrar speaking con grabaciones reales. Segunda etapa: SSO con Google, app móvil y analítica pedagógica avanzada.

CRITERIO ANTES QUE INFRAESTRUCTURA

Simple hoy, con el camino marcado.

No se construyó infraestructura que un prototipo no necesita. Cada atajo quedó marcado en el código con un comentario `ponytail`: que dice dónde está su límite y qué lo reemplaza.

HOY	LÍMITE	A ESCALA
Rate limit en memoria	Con N réplicas, el límite efectivo es N veces el configurado	Redis (INCR + EXPIRE) con la misma interfaz
Caché TTS en memoria (LRU 50)	Se pierde al reiniciar y no se comparte entre réplicas	mp3 en S3/R2 servido por CDN, clave por hash del texto
Feedback IA en la petición	Retiene una conexión a la BD mientras responde el LLM	Cola (arq, Celery o SQS) y el cliente consulta el estado
Panel docente sobre los últimos 2.000 intentos	Se agrega en memoria	Tabla de resumen por estudiante, paginada por grupo
Audios de Listening en disco	Viajan con la imagen	Almacenamiento de objetos con URL firmada de corta duración
Catálogo de cursos en código	Lo edita un desarrollador	Tabla <code>courses</code> editable por el equipo académico
Umbrales de speaking a ojo	Sin calibrar con datos	Calibrar con grabaciones reales y revisión docente

Roadmap sugerido a producción

Mes 1

Operar con confianza

- Sentry, métricas y alertas
- Backups y restauración probada
- Redis para límites y caché
- Cola para IA y TTS

Mes 2

Contenido y pedagogía

- CMS de preguntas para docentes
- Banco validado por nivel
- Calibración de speaking
- Grupos y cohortes

Mes 3

Crecer

- SSO con Google
- Integración CRM del embudo
- E2E con Playwright
- Más mini clases con Glo

Segunda etapa: app móvil nativa, pruebas adaptativas (CAT), analítica de aprendizaje y certificación.



See you in **class**.

Nos vemos en clase. Pruébalo con las cuentas demo del login:

estudiante@globalai.demo · **profesor@globalai.demo** ·
contraseña **Demo1234!**