



Mini Global AI Assessment

Decisiones técnicas

Evaluación de inglés con login, test de 10 preguntas (+3 de Speaking), calificación en el servidor, resultado por habilidad, registro de intentos, progreso y feedback con IA, acompañada por Glo, un coach con voz.




Jhon

24 · 09 · 2026

Astro · FastAPI · PostgreSQL
github.com/Jhondlp/GlobalAI

1 Arquitectura




2 Decisiones de stack

ELECCIÓN	POR QUÉ	DESCARTADO
Astro	Envía solo el JS que cada página necesita: carga rápida en conexiones modestas.	SPA React/Next: más JS por defecto.
FastAPI async	Pydantic valida en el borde, OpenAPI gratis y async para no bloquear mientras responde la IA.	Django: más peso del necesario.
PostgreSQL	FOR UPDATE al enviar, índice parcial único y JSONB. Portable a Neon, Supabase o RDS.	NoSQL: pierde integridad relacional.
Cookie httpOnly	JS no puede leer el token: un XSS no roba sesiones. También acepta Bearer para Swagger y apps.	JWT en localStorage.

3 Modelo de datos: crecer sin rehacer

- Niveles y habilidades son filas** (`levels.rank`), no código: Pre-A1 → C1 ya existen y agregar C2 es un INSERT.
- Banco de preguntas reutilizable** (`questions + stimuli`) separado de la evaluación (`assessment_questions` con posición y puntos). Varias preguntas en la misma posición son **variantes**.
- Enums como VARCHAR**: un tipo de pregunta nuevo no exige migración.
- attempts**: layout generado por el servidor, vencimiento y resultado **congelado**; cambiar reglas no reescribe el historial.
- attempt_answers**: UNIQUE(intento, pregunta), así el autoguardado es un upsert idempotente. **attempt_events**: bitácora de integridad.
- Un solo intento abierto** garantizado por un índice parcial único `WHERE status='in_progress'`. El progreso se deriva de los intentos, indexado por (`user_id, submitted_at`).

4 Seguridad: el navegador propone, el servidor decide



- Speaking y Listening protegidos**: el audio se califica en la API y el Listening nunca envía su transcripción.
- Variante menos vista + orden aleatorio por intento**: memorizar la revisión no sirve.
- Integridad**: cambio de pestaña, pegar, < 3 s por respuesta (medido con reloj del servidor). Es evidencia para el profesor, nunca baja la nota.
- Roles**: `require_roles`(TEACHER, ADMIN) por router; los datos siempre se filtran por dueño.
- Cuentas**: bcrypt en hilo aparte, hash falso contra enumeración y rate limit (5 fallos por IP+email, 120 req/min, 10/min en rutas con costo de IA).
- Operación**: no arranca en producción sin `JWT_SECRET` fuerte; CSP y `nosniff`; al LLM no viaja nombre ni email.

5 Calificación e IA

Reglas puras

Nota explicable

Texto normalizado (NFKC, mayúsculas, apóstrofes). Nivel sugerido: $\geq 50\%$ en el nivel y $\geq 60\%$ **acumulado** hacia abajo; un error aislado en A1 no hunde a quien domina B1.

Speaking

Cuatro métricas

Precisión (lectura), rúbrica 0-4 del LLM (respuesta libre), claridad y fluidez del STT. $\text{contenido} \times (0.6 + 0.2 \cdot \text{claridad} + 0.2 \cdot \text{fluidez})$. Máx. 3 grabaciones.

Proveedor

Cambiar de IA = un campo del .env

`AI_PROVIDER=anthropic|openai|mock`, sin tocar código. `OPENAI_BASE_URL` abre Groq, OpenRouter, Ollama o Gemini. Feedback una vez por intento y TTS en caché.

El LLM redacta, explica y conversa; **nunca** decide una nota objetiva, el nivel ni qué curso se ofrece (`domain/courses.py` es determinista).

6 Resiliencia y calidad

Si se pierde la conexión

Las respuestas quedan en `localStorage` y en cola; al volver la red se reenvían (PUT idempotente). Recargar **reanuda** el mismo intento y orden. El envío final incluye lo pendiente, hay 30 s de gracia y una página offline.

68 tests + CI/CD

Primero lo que rompe la confianza en la nota: respuestas ocultas, envío idempotente, vencimiento, permisos, nivel sugerido y speaking. GitHub Actions corre ruff + pytest contra **Postgres 17 real**, build de la web, smoke test con `docker compose` y publica la imagen en GHCR.

7 Producto (más allá del mínimo)

Glo, el coach

Mascota 3D propia que reacciona, habla con voz, usa un sombrero según el nivel y da una mini clase de pronunciación con charla y corrección.

Resultado → matrícula

Curso recomendado según nivel y habilidades débiles, presentado por Glo con voz, CTA a un asesor e imagen para compartir el nivel en redes.

Panel docente

Niveles del grupo, promedios por habilidad y alertas (puntaje bajo, caída, ayuda externa) calculadas en el servidor. Exporta CSV.

8 De 100 a 100.000 estudiantes

HOY (PROTOTIPO)

A ESCALA

Rate limit y caché TTS en memoria	Redis (<code>INCR + EXPIRE</code>) y mp3 en S3/R2 detrás de un CDN. La API ya es stateless, así que escala horizontalmente.
Feedback IA dentro de la petición	Cola (arq, Celery o SQS) y el cliente consulta el estado; libera conexiones de BD.
Conexiones directas a Postgres	PgBouncer (ya soportado con <code>DB_USE_PGBOUNCER</code>) y réplicas de lectura para reportes.
Panel docente sobre 2.000 intentos	Tabla de resumen por estudiante, paginada por grupo. Cada atajo está marcado en el código con <code>ponytail:</code> .

9 Preguntas de la entrevista, en una línea

01 100k usuarios: Redis, cola para IA, PgBouncer y tabla de resumen (tabla de arriba).

02 Ver respuestas: `answer_key` nunca se serializa antes del envío (hay un test que lo verifica).

03 Progreso: Postgres; intentos como snapshots + respuestas por fila + eventos.

04 Más niveles: ya son datos (`levels.rank`); un nivel nuevo es un INSERT.

05 Cambiar de IA: solo el .env: `AI_PROVIDER` + su key. Cero código.

06 Roles: rol en `users`, verificado en BD en cada petición + `require_roles`.

07 Sin conexión: cola local, PUT idempotente, reanudación exacta y 30 s de gracia.

08 Modificar la nota: ningún endpoint la acepta; se calcula con `FOR UPDATE` y se congela.

09 Tests primero: reglas de calificación y API del intento; después E2E.

10 Producción en 3 meses: ver la sección siguiente.

10 Producción en tres meses

Mes 1 · Operar

Sentry y métricas, backups probados, Redis, cola para IA/TTS y deploy con migraciones automáticas.

Mes 2 · Contenido

CMS de preguntas para docentes, banco validado por nivel, calibración de speaking con grabaciones reales y cohortes.

Mes 3 · Crecer

SSO con Google, CRM del embudo, E2E con Playwright y más mini clases. **Después:** app nativa y pruebas adaptativas.